

Pronóstico de demanda semanal en una red de centros de distribución de comida

Trabajo Práctico Integrador — Módulo R
Laboratorio de Programación en Python y R
Maestría en Econometría, Universidad Torcuato Di Tella

Diego Contreras

21 de septiembre de 2026

Contenido

Resumen ejecutivo	2
1 Parte 1 — Elección del dataset y de la técnica	3
1.1 Elección del dataset y motivación	3
1.2 Elección del método	3
1.3 Utilización del paquete <code>fable</code> y <code>no forecast</code>	4
2 Parte 2 — Análisis exploratorio	5
2.1 Estructura general	5
2.2 La serie a pronosticar	5
2.3 Valores faltantes	5
2.4 Distribución de la variable dependiente	7
2.5 Precios y descuentos	8
2.6 Relaciones bivariadas relevantes para la técnica	10
2.7 Heterogeneidad entre categorías y centros	12
2.8 Análisis de la caída de la semana 62	13
2.9 Propiedades de serie de tiempo	14
3 Parte 3 — Aplicación de la técnica e interpretación	17
3.1 Diseño de la evaluación	17
3.2 Modelos estimados	17
3.3 Resultado de la evaluación	18
3.4 Diagnóstico de residuos	20
3.5 Interpretación económica	21
3.6 Nivel de agregación: ¿dónde sirve conocer el plan comercial?	23
3.7 Proyección final para las semanas 146 a 155	26
4 Limitaciones del análisis	30
5 Conclusiones	31
Anexo — Reproducibilidad	31

Resumen ejecutivo

Este trabajo analiza el historial de pedidos semanales de una empresa de reparto de comida que opera 77 centros de distribución y un catálogo de 51 platos, y construye un sistema de pronóstico a diez semanas para apoyar la planificación de la compra de insumos perecederos y la dotación de personal. El dataset proviene de una competencia pública de Kaggle y contiene 456.548 observaciones semanales que cubren 145 semanas de operación.

La técnica aplicada es **modelado de series de tiempo ARIMA / SARIMA / ARIMAX**, implementada con el ecosistema `tsibble` / `fable` del tidyverse. El trabajo llega a tres resultados importantes, a saber:

1. **La evaluación con una sola ventana de backtesting elige el modelo equivocado.** El pronóstico ingenuo (modelo ‘naive’ que consiste en repetir el último valor observado) gana con holgura en la ventana de validación de diez semanas, pero cae al quinto puesto de seis cuando el ejercicio se repite con validación cruzada de origen móvil. Todo el diseño de evaluación del trabajo se apoya en esa corrección.
2. **Forzar un componente estacional no mejora nada.** Con 2,8 años de historia, la búsqueda automática elige exactamente el mismo modelo con y sin estacionalidad anual habilitada. O sea, la estacionalidad no se impone.
3. **Incorporar las decisiones comerciales de la empresa (precios y promociones) mejora el pronóstico solo en un nivel de agregación intermedio.** Gana en 11 de 12 categorías de producto, pero pierde tanto en el agregado total como en las series individuales centro-plato. La razón es que, para que tengan efecto, los regresores tienen que continuar siendo variables en el período que se quiere proyectar, y en las semanas proyectadas eso no ocurre sobre las combinaciones analizadas.

1. Parte 1 — Elección del dataset y de la técnica

1.1. Elección del dataset y motivación

El dataset elegido es **Food Demand Forecasting**, publicado en Kaggle a partir de un problema real de la plataforma de competencias Analytics Vidhya. Describe la operación de una empresa de reparto de comida que atiende múltiples ciudades a través de centros de distribución propios. Cada fila del archivo principal registra, para una semana determinada, cuántos pedidos recibió un determinado plato en un centro particular, junto con el precio que efectivamente se cobró, el precio de lista y dos indicadores de acción promocional, a saber: promoción por e-mail y destacado en la página de inicio de la web.

Tabla 1: Archivos que componen el dataset

Archivo	Filas	Vars.	Contenido
train (semanas 1-145)	456.548	9	Pedidos semanales por centro y plato
test (semanas 146-155)	32.573	8	Similar pero sin la variable a predecir
meal_info	51	3	Dimensiones de platos: categoría y tipo de cocina
fulfilment_center_info y área de operación	77	5	Dimensiones de centros: ciudad, región, tipo

La pregunta sustantiva es operativa y está enunciada por la propia empresa de la siguiente manera: **¿cuántos pedidos va a recibir cada centro en las próximas diez semanas?** Motiva la pregunta dos razones económicas. La primera es que la materia prima es perecedera y se repone semanalmente. Sobreestimar la demanda generaría desperdicio, y subestimarla generaría quiebres de stock y ventas perdidas. La segunda es que la dotación de personal de cada centro se planifica, de modo que un pronóstico sesgado se traduce en costo laboral ocioso o en demoras de entrega.

A esa pregunta operativa se agrega una segunda, de naturaleza econométrica, que los datos permiten responder: **¿cuánto aporta conocer el plan comercial de la empresa (sus precios y sus promociones) para anticipar la demanda?** Los datos permiten responder esta pregunta porque los precios y las promociones de las semanas a proyectar están disponibles, como decisiones que la empresa ya tomó. Eso permite un ejercicio de pronóstico con variables exógenas genuinamente conocidas, sin tener que suponer nada sobre su trayectoria futura.

El tamaño del dataset es holgado para un análisis exploratorio serio. Son 456.548 observaciones, nueve variables en el archivo principal y dos tablas de dimensiones que agregan la categoría y el tipo de cocina de cada plato, y la ciudad, la región, el tipo y el área de operación de cada centro.

1.2. Elección del método

A continuación, se justifica la elección del método utilizado para resolver el problema, explicando también el descarte de otras técnicas econométricas disponibles.

- **Series de tiempo (elegida).** La variable dependiente es un conteo semanal indexado por un período regular, sin huecos a nivel agregado, y la necesidad es una proyección a un horizonte fijo de diez semanas. Además, la disponibilidad de los regresores en el período a proyectar habilita un ARIMAX.
- **Regresión lineal con regularización.** Sería aplicable si el objetivo fuera explicar el nivel de pedidos con un conjunto grande de covariables, pero ignoraría por completo la dependencia temporal. Con 145 semanas y menos de diez predictores, no existe el problema de dimensionalidad que motiva la aplicación de otros métodos como Ridge o LASSO.
- **Regresión logística y modelos lineales generalizados.** No hay ninguna variable binaria que sea la respuesta de interés. Un GLM Poisson o binomial negativo sería defendible para modelar el conteo de pedidos, pero sin estructura temporal explícita perdería lo que define al problema.
- **Datos de panel.** Esta era una alternativa seria porque el dataset es un panel: 3.597 combinaciones centro-plato observadas hasta 145 veces. Un modelo de efectos fijos respondería preguntas del tipo “¿cuánto aumenta la demanda de un plato cuando se lo destaca en la página principal, controlando por todo lo invariante de ese plato y ese centro?”. Es una pregunta legítima, pero **de identificación, no de proyección**. Como la pregunta del problema es de proyección, la técnica correcta es la de series de tiempo. No obstante, en la Parte 3 se recupera parcialmente la dimensión de panel, estimando el modelo por separado en varios niveles de agregación.

1.3. Utilización del paquete `fable` y `no forecast`

En clase la modelización de series de tiempo se trabajó con objetos `ts` y el paquete `forecast` (`auto.arima`, `checkresiduals`, `forecast`). Este trabajo usa `tsibble` y `fable`, la generación siguiente de los mismos autores. La técnica econométrica es idéntica (ARIMA, SARIMA, ARIMAX, con la misma selección automática por criterios de información) y el cambio es de implementación, por cuatro razones prácticas:

1. **Consistente con la sintaxis de tidyverse** `fable` provee herramientas para evaluar, visualizar y combinar modelos en un flujo de trabajo coherente con `tidyverse`, que es una colección de paquetes de R que comparten una filosofía de diseño y estructuras de datos comunes.
2. **El dataset es un panel, no una serie.** `fable` estima el mismo modelo sobre todas las series de un `tsibble` con clave múltiple en una sola llamada. Un objeto `ts` obliga a escribir un bucle sobre cada serie.
3. **Los faltantes son explícitos.** `tsibble` distingue entre “no hay registro” y “hay un cero”, que es precisamente la distinción central del análisis exploratorio de este dataset.
4. **La comparación de modelos es nativa.** `accuracy()` sobre varios modelos y varias series, y `stretch_tsibble()` para validación cruzada de origen móvil, son parte del flujo estándar del paquete.

2. Parte 2 — Análisis exploratorio

2.1. Estructura general

El panel cubre 145 semanas consecutivas, pero sin fechas de calendario, porque el dataset identifica los períodos con un índice entero de 1 a 145. Para poder hablar de frecuencia semanal y habilitar modelos con componente estacional anual, anclamos la semana 1 a la primera semana de 2016. Es una convención de indexado que no altera ningún resultado.

La combinación de 77 centros y 51 platos admite 3.927 pares posibles, de los cuales se observan 3.597 (el 91,6 %). La variable dependiente es `num_orders`, el número de pedidos de la semana, y las variables candidatas a regresor son el precio cobrado, el precio de lista y dos indicadores binarios de promoción.

2.2. La serie a pronosticar




Figura 1: Demanda total semanal de la red. La franja sombreada marca la ventana de validación utilizada en la Parte 3.

La demanda total semanal oscila alrededor de una mediana de 809.625 pedidos, sin tendencia marcada y con una variabilidad considerable. Dos episodios saltan a la vista: el máximo de la semana 48 y, más importante aún, la caída de la semana 62, que tuvo 380.065 pedidos, un 53 % por debajo de la mediana.

2.3. Valores faltantes

Ninguna columna del dataset tiene valores faltantes (NA). Sin embargo, el problema de datos faltantes existe y es el hallazgo estructural más importante del análisis exploratorio: **el panel es desbalanceado**. De las 3.597 combinaciones centro-plato observadas, solo 1.247 tienen las 145 semanas completas.

Tabla 2: Estructura de la ausencia de registros en el panel

Situación	Combinaciones	% del total
historia completa (145 semanas)	1.247	34,7 %
alta tardía (el plato aparece después de la semana 1)	675	18,8 %
baja temprana (el plato deja de ofrecerse antes de la 145)	329	9,1 %
con huecos internos (semanas sueltas sin registro)	2.129	59,2 %




Figura 2: Cuántas semanas vive cada combinación centro-plato.




Figura 3: Patrón de presencia de una muestra de 150 combinaciones. Las zonas en blanco son semanas sin registro.

La segunda figura muestra que el patrón de faltantes no es aleatorio. La escalera que se forma en el borde superior corresponde a platos dados de alta progresivamente; los cortes horizontales y largos, a platos discontinuados y reincorporados. Parece un comportamiento consistente con la gestión de un menú, no con un problema de recolección.

A pesar de los valores faltantes implícitos, se decidió no imputar ceros. La decisión es verificable en los datos: el mínimo de `num_orders` en todo el dataset es 13, nunca cero. Si la ausencia de un registro significara “se ofreció y no se vendió”, deberían existir registros con valor cero. Que no existan indica que su ausencia significa que el plato no estaba disponible en ese centro esa semana. Imputar ceros introduciría demanda falsa y sesgaría a la baja toda estimación.

En consecuencia, la estrategia de modelado evita el problema por diseño en lugar de taparlo con una imputación: se trabaja en niveles de agregación donde la suma se toma sobre los platos efectivamente ofrecidos (de modo que el faltante no genera un hueco en la serie, que torna inaplicables algunos métodos), y cuando se baja al nivel individual se usan únicamente combinaciones con historia completa. Como control adicional, la cantidad de ítems activos por semana entra al modelo como variable explicativa, de manera que la expansión del catálogo no se confunda con crecimiento de la demanda por ítem.




Figura 4: Amplitud del menú activo por semana.

A nivel de categoría el mismo fenómeno aparece con una granularidad mayor: **Fish** recién aparece en la semana 59 y **Salad** tiene un hueco de tres semanas. Ambas se excluyen del modelado comparativo por categoría, para que la comparación entre familias se haga sobre la misma ventana temporal. Representan en conjunto el 9,9 % del volumen histórico, y se las tiene en cuenta al evaluar la coherencia entre niveles en la Parte 3.

2.4. Distribución de la variable dependiente

Tabla 3: Distribución de los pedidos semanales por combinación centro-plato

Mínimo	P25	Mediana	Media	P75	P99	Máximo	Asimetría
13	54	136	262	324	1.796	24.299	7

La distribución es fuertemente asimétrica: la mediana es de 136 pedidos, el percentil 99 de 1.796 y el máximo de 24.299. El coeficiente de asimetría es de 6,9.




Figura 5: Distribución de pedidos en escala logarítmica.

En logaritmos la distribución se vuelve aproximadamente simétrica. Por esta razón, todos los modelos de la Parte 3 se estiman sobre el logaritmo de los pedidos. La transformación no es cosmética; cumple tres funciones. Garantiza proyecciones estrictamente positivas, hace que los errores sean proporcionales al nivel de la serie (errar por mil pedidos no significa lo mismo en una serie de cinco mil que en una de doscientos mil), y convierte los coeficientes en efectos porcentuales, que es la unidad en que se toman las decisiones comerciales.

Finalmente, los valores extremos no se eliminan. Las observaciones de la cola derecha corresponden a los platos más vendidos en los centros más grandes durante semanas de promoción. Son demanda real y son justamente las que más importa proyectar bien. La escala logarítmica ya limita su influencia sobre la estimación.

2.5. Precios y descuentos

La variable de precios más informativa es el descuento efectivo, definido como la diferencia relativa entre el precio de lista y el precio cobrado. Al construirla aparece algo que cabe notar: **en el 25,4% de las filas el precio cobrado es mayor que el precio de lista**, de modo que el descuento es negativo, y llega hasta un recargo del 73%.




Figura 6: Distribución del descuento efectivo. La zona sombreada corresponde a recargos.

Aún así, los valores negativos se conservaron con su signo. No son un error de carga sino una política de precios. Posiblemente, la empresa cobra por encima del precio de referencia en un cuarto de las transacciones, lo que es consistente con sobreprecios por franja horaria, por zona o por demanda alta. Truncarlos en cero descartaría exactamente la mitad de la variación de precios disponible, que es la que permite estimar cómo responde la cantidad al precio. La alternativa (tratar los recargos como categoría aparte) se descartó por simplicidad y porque los datos no la sostendrían: los recargos que superan el 2 % son apenas el 0,8 % de las filas, y los que superan el 25 % son 111 observaciones sobre 456.548. No hay masa suficiente para estimar una respuesta separada del lado de los aumentos de precio.

2.6. Relaciones bivariadas relevantes para la técnica





Figura 7: Pedidos según el tipo de acción promocional (escala logarítmica).

La mediana de pedidos pasa de 122 sin ninguna acción promocional a 474 cuando se combinan campaña de correo y destaque en la página principal, prácticamente se cuadruplica. No obstante, se debe interpretar con cautela: la promoción no se asigna al azar, y es razonable pensar que la empresa promocioe justamente los platos que espera vender bien. De todas formas, sugiere que hay señal suficiente para justificar un modelo con regresores.

La segunda relación bivariada que interesa es la que hay entre el precio y la cantidad, y exige una advertencia metodológica antes de mirarla. El descuento está definido en relación al precio de lista de cada plato, pero los pedidos están en niveles absolutos, y los niveles varían enormemente entre productos: la mediana es de 136 pedidos y el máximo de 24.299. Un gráfico que junte las 3.597 combinaciones centro-plato está comparando productos distintos entre sí, y esa variación de escala aplasta la respuesta al precio, que es un fenómeno de cada producto consigo mismo a lo largo del tiempo.

La respuesta al precio se ve dentro de cada producto

A la derecha se le resta a cada observación el promedio histórico de su propia combinación centro-plato



Muestra aleatoria de 40.000 observaciones sobre combinaciones con al menos 30 semanas Semilla = 2026.
Restar la media de cada producto equivale a incluir un efecto fijo. La pendiente pasa de 1.76 a 2.63 y el R^2 se multiplica por 7.1.

Figura 8: Respuesta de la cantidad al precio, medida de dos maneras sobre los mismos datos.

La figura muestra las dos lecturas una al lado de la otra. En el panel izquierdo, agrupando todo, la nube es difusa: la pendiente es de 1,76 pero el ajuste explica apenas el 2,7 % de la variación. En el panel derecho, donde a cada observación se le resta el promedio histórico de su propia combinación centro-plato (lo que equivale a incluir un efecto fijo por producto), la relación aparece con nitidez: la pendiente sube a 2,63 y el poder explicativo se multiplica por 7,1, hasta el 19,3 %. La correlación pasa de 0,16 a 0,44.

La lectura sustantiva es que **la demanda sí responde al precio, pero esa respuesta es intra-producto y un análisis agrupado la esconde**. Es el mismo fenómeno de variable omitida que aparece cuando se ignora una dimensión relevante de los datos: el nivel medio de cada plato está correlacionado tanto con sus pedidos como con su política de precios, de modo que no controlarlo sesga la estimación hacia cero.

Cabe notar dos precauciones adicionales sobre este gráfico:

La primera es que el descuento está muy concentrado: el 73,6 % de las filas se mueve dentro de una banda de más o menos dos puntos porcentuales alrededor de cero, que es la columna vertical visible en ambos paneles. Por eso se usa un ajuste lineal y no un suavizado local (un LOESS sobre una variable tan concentrada queda dominado en cada vecindad por esa columna y devuelve una curva plana que no informa nada, y en la zona de recargos profundos, donde hay unos pocos cientos de observaciones, directamente extrapola ruido).

La segunda es que el descuento a veces está acompañado de la promoción. La proporción de ítems promocionados pasa del 4,6 % entre los que no tienen descuento al 58,7 % entre los que tienen más de 30 %, de modo que parte de lo que mide esta pendiente es el efecto de la promoción que suele acompañar al descuento. Separar ambos efectos es precisamente lo que hace el modelo con variables exógenas de la Parte 3, que los incluye juntos.

2.7. Heterogeneidad entre categorías y centros




Figura 9: Demanda semanal por categoría de plato.

Las escalas son muy distintas: **Beverages** mueve alrededor de 280.000 pedidos semanales y **Biryani** unos 4.400, lo que obliga a usar métricas de error comparables entre series (MASE) y no solo el error cuadrático medio. En casi todos los paneles se ve la misma caída sincronizada alrededor de la semana 62.




Figura 10: Escala del centro y demanda semanal promedio.

El área de operación del centro explica buena parte de la dispersión del volumen, y los centros de tipo B concentran los mayores volúmenes pese a ser los menos numerosos.

2.8. Análisis de la caída de la semana 62




Figura 11: Caída de la semana 62 medida centro por centro.

La caída de la semana 62 no es un valor atípico de la serie: **los 77 centros caen simultáneamente más de un 30 % respecto de su propio promedio local**, y ninguno queda por


encima del 65 %. Un shock de demanda genuino no tiene por qué afectar a todas las ciudades y todas las categorías en la misma semana y con la misma intensidad. El patrón es compatible con una interrupción operativa de la plataforma o con un problema de registro que afectó a toda la semana.

En este caso, el dato no se elimina ni se interpola, sino que se modela mediante una variable de intervención, es decir, una variable indicadora que vale uno en la semana 62 y cero en el resto. El razonamiento es que el episodio está identificado, es de causa única y no es recurrente: borrarlo equivaldría a pretender que no ocurrió, e interpolarlo inventaría un dato. Dejarlo sin tratar, en cambio, inflaría la varianza residual del modelo y ensancharía artificialmente todos los intervalos de pronóstico. La variable de intervención permite conservar el dato y aislar su efecto. La estimación de ese efecto se reporta en la Parte 3.

2.9. Propiedades de serie de tiempo

Descomposición STL de la demanda total semanal

El componente estacional (sd 98.800) es del mismo orden que el residuo (sd 104.200) y mucho mayor que la tendencia (sd 42.300)



STL robusta (robust = TRUE). Con solo 2,8 ciclos anuales la estacionalidad esta debilmente identificada: parte del pico de la semana 48 se absorbe como 'estacional'. Por eso la estacionalidad se testea, no se impone.

Figura 12: Descomposición STL de la demanda total semanal.

La descomposición muestra una tendencia muy débil (fuerza de tendencia 0,11) frente a un componente estacional de fuerza 0,54 y un residuo del mismo orden de magnitud que ese componente estacional. Con 145 semanas hay apenas 2,8 ciclos anuales, de modo que un patrón anual está débilmente identificado y parte de lo que la descomposición atribuye a “estacionalidad” es en realidad un episodio puntual (el pico de la semana 48) que no tiene por qué repetirse. Por eso en la Parte 3 la estacionalidad se somete a prueba en lugar de asumirse.

Autocorrelación de la demanda total semanal

Decaimiento rápido en la ACF y corte en la PACF: patrón compatible con un AR de orden bajo, sin raíz unitaria




Figura 13: Funciones de autocorrelación y autocorrelación parcial.


Tabla 4: Test de Dickey-Fuller aumentado

Serie	Estadístico	p-valor	Conclusión
pedidos (nivel)	-4,79	0,01	se rechaza raíz unitaria
primera diferencia	-8,97	0,01	se rechaza raíz unitaria

La función de autocorrelación decae rápidamente y el test de Dickey-Fuller aumentado rechaza la hipótesis de raíz unitaria en niveles. Esto implica que la serie ya es estacionaria sin necesidad de diferenciar, de modo que un modelo que diferencie estaría sobre-diferenciando.

Las tres palancas comerciales, semana a semana

Son variables de decisión de la empresa y están disponibles para las semanas 146-155: por eso habilitan un ARIMAX



Correlación contemporánea con los pedidos totales: 0,37 (descuento), 0,47 (email), 0,43 (home).

Figura 14: Las tres palancas comerciales a lo largo del tiempo.

Las correlaciones contemporáneas de los pedidos totales con las tres palancas comerciales son de 0,37 con el descuento medio, 0,47 con la proporción de ítems con campaña de correo y 0,43 con la proporción de ítems destacados. Son magnitudes suficientes para justificar un modelo con variables exógenas.

3. Parte 3 — Aplicación de la técnica e interpretación

3.1. Diseño de la evaluación

En esta parte se elige entre modelos. En series de tiempo la partición de los datos no puede ser aleatoria: el conjunto de validación tiene que ser posterior al de entrenamiento, porque de lo contrario el modelo usa información del futuro para predecir el pasado.

Se usan dos esquemas:

1. **Backtesting sobre una ventana.** Se estima con las semanas 1 a 135 y se proyectan las semanas 136 a 145, que existen en los datos pero que ningún modelo vio al estimarse. Este esquema replica el del problema original.
2. **Validación cruzada de origen móvil.** El mismo ejercicio se repite desplazando el punto de corte. Se entrena con las primeras noventa semanas, se proyectan diez, se avanza cinco semanas y se vuelve a empezar, hasta obtener once ventanas. Es el análogo temporal de la validación cruzada en k bloques.

Los regresores del modelo con variables exógenas son conocidos en el período proyectado en ambos esquemas. Constituyen las decisiones de precio y promoción que la empresa ya tomó y registró, y reproducen la situación real de planificación, en la que el área comercial define el plan y logística proyecta la demanda condicional a ese plan.

3.2. Modelos estimados

Tabla 5: Especificación seleccionada automáticamente por cada modelo

Modelo	Especificación elegida
ARIMA (orden de integración libre)	ARIMA(0,1,2)
ARIMA estacionario ($d = 0$ impuesto)	ARIMA(2,0,3) w/ mean
SARIMA (estacionalidad de período 52 habilitada)	ARIMA(0,1,2)
ARIMAX (con precios, promociones e intervención)	LM w/ ARIMA(1,0,0) errors

La tabla contiene el primero de los dos resultados metodológicos del trabajo. La fila del SARIMA muestra que **al habilitar el componente estacional de período 52, la búsqueda automática elige exactamente el mismo modelo que sin él**: ARIMA(0,1,2), sin ninguna parte estacional. El criterio de información no encuentra ganancia en la estacionalidad anual, lo que es consistente con lo que anticipaba la descomposición: 2,8 ciclos no alcanzan para identificar un patrón anual.

En relación a la segunda fila, cuando el orden de integración se deja libre, la selección automática de **fable** (que se basa en el test KPSS) elige diferenciar una vez. Pero el test de Dickey-Fuller aumentado de la Parte 2 rechazaba la raíz unitaria, es decir, indicaba lo contrario. En lugar de elegir una, se estiman ambas especificaciones y se deja que decida el error de proyección fuera de muestra.

3.3. Resultado de la evaluación




Figura 15: Proyección de cada modelo contra los valores efectivamente observados en las semanas 136 a 145.

Tabla 6: RMSE fuera de muestra bajo los dos esquemas de evaluación

Modelo	RMSE ventana 136–145	RMSE validación cruzada
arima_d0	97.143	96.417
arima	117.587	97.184
arimax	73.684	97.271
ets	149.265	100.671
naive	54.794	126.458
snaive	115.161	145.228
sarima	117.587	—





Figura 16: El mismo conjunto de modelos evaluado de dos maneras distintas.

Éste es el segundo resultado metodológico, y es el que más condiciona todo lo que sigue. **En la ventana única el ganador es el pronóstico ingenuo (naive)**, con un RMSE de 54.794 pedidos, muy por debajo de cualquier modelo estimado. Esto lleva a concluir que ningún modelo aporta nada en comparación a repetir el último valor observado.

No obstante, la validación cruzada muestra que esa conclusión depende de la ventana elegida. Sobre once ventanas, el pronóstico ingenuo pasa a un RMSE de 126.458 pedidos (más del doble), y queda quinto entre seis modelos. Lo que había ocurrido es que el nivel de la semana 135 resultó casi idéntico al promedio de las diez semanas siguientes, una coincidencia que no se repite en otros cortes.

El modelo seleccionado es el **ARIMA estacionario**, con un RMSE de 96.417 pedidos, equivalente a un error porcentual absoluto medio de 9,2%. Nótese que le gana al ARIMA con diferenciación automática: **el test de Dickey-Fuller tenía razón y diferenciar era sobre-diferenciar**. La diferencia es modesta pero consistente, y resuelve empíricamente la discrepancia entre los dos tests de raíz unitaria.



El error no crece, principalmente porque la serie no tiene tendencia y vuelve rápido a su media.

Figura 17: Error de proyección según el horizonte.

Una particularidad de esta serie: el error **no** crece con el horizonte de proyección, a diferencia de lo que ocurre habitualmente. Esto es consecuencia directa de la ausencia de tendencia: la serie revierte rápido a su media, de modo que proyectar a diez semanas no es sustancialmente más difícil que proyectar a dos. Esto sería una buena noticia operativa, porque la planificación a diez semanas no es materialmente menos confiable que la planificación a dos semanas.

3.4. Diagnóstico de residuos




Figura 18: Residuos del modelo con variables exógenas.




Figura 19: Autocorrelación de los residuos.

Se diagnostica el modelo con variables exógenas, que es el que responde la pregunta económica del trabajo. Los residuos no muestran estructura visible ni cambios de varianza, y la autocorrelación se mantiene dentro de las bandas de confianza en todos los rezagos. El test de Ljung-Box con 24 rezagos arroja un p-valor de 0,50, de modo que no se rechaza la hipótesis de que los residuos sean ruido blanco. El modelo no está dejando estructura temporal sin aprovechar.

3.5. Interpretación económica

Tabla 7: Coeficientes del modelo con variables exógenas sobre el logaritmo de los pedidos

Variable	Coeficiente	Error estándar	p-valor	
Componente autorregresivo (AR1)	0,291	0,085	< 0,001	***
Descuento medio del menú	1,584	0,807	0,052	*
Proporción de ítems con campaña de correo	0,578	0,254	0,025	**
Proporción de ítems destacados en la página principal	1,234	0,505	0,016	**
Amplitud del menú activo	0,000	0,000	0,004	***
Intervención de la semana 62	-0,653	0,106	< 0,001	***




Figura 20: Efecto estimado de cada palanca comercial.

Como la variable dependiente está en logaritmos, cada coeficiente se lee como el efecto porcentual aproximado de aumentar el regresor en una unidad. Los tres coeficientes comerciales son positivos y significativos al 5 % o al 10 %, con el signo que la teoría predice.

El coeficiente de la intervención de la semana 62 es de -0,65, lo que implica una caída del 48 % respecto de lo que el modelo esperaba para esa semana dadas las condiciones comerciales vigentes. Cerca de la mitad de la demanda semanal de toda la red.

Ahora bien, los coeficientes sobre los regresores comerciales están expresados por unidad, y las unidades son proporciones entre cero y uno. Un aumento de una unidad en “proporción de ítems con campaña de correo” significa pasar del 0 % al 100 % del menú, algo que la empresa nunca hizo. La lectura relevante es la que traduce esos coeficientes a movimientos dentro del rango en que la empresa efectivamente opera:

Tabla 8: Efecto de pasar del percentil 25 al percentil 75 de cada palanca comercial

Palanca	Movimiento P25 → P75	Efecto sobre la demanda	p-valor
Descuento medio del menú	2,1 p.p.	+3,4 %	0,052
Proporción de ítems con campaña de correo	6,8 p.p.	+4,0 %	0,025
Proporción de ítems destacados	4,2 p.p.	+5,3 %	0,016

De esta forma, **los efectos son estadísticamente significativos pero económicamente modestos en el agregado**: entre 3 % y 5 % de la demanda total. La razón es que la empresa mueve estas palancas dentro de un rango estrecho a nivel de red: el rango intercuartil de la proporción de ítems con campaña de correo es de apenas 6,8 puntos porcentuales. El efecto por unidad es grande, pero la variación observada es pequeña.

Esto explica un resultado extraño: aunque el modelo con variables exógenas ajusta mucho mejor dentro de muestra (su criterio de información corregido es de -204 contra -125 del modelo sin

regresores), es decir, **no mejora la proyección fuera de muestra a nivel agregado**: su RMSE en validación cruzada es de 97.271 contra 96.417. Mejor ajuste dentro de muestra no implica necesariamente mejor pronóstico fuera de ella.

3.6. Nivel de agregación: ¿dónde sirve conocer el plan comercial?

El resultado anterior sugiere una hipótesis: la información promocional se diluye al agregar sobre 3.597 combinaciones, porque las campañas individuales se compensan entre sí. Si eso fuera cierto, el modelo con regresores debería mejorar a medida que se desagrega. Se puso a prueba estimando el mismo par de modelos en dos niveles adicionales: las doce categorías de plato con historia completa, y las seis combinaciones centro-plato de mayor volumen.

Tabla 9: Desempeño del modelo con y sin variables exógenas en tres niveles de agregación

Nivel	MASE sin regresores	MASE con regresores	Ganancia
Red completa (1 serie)	0,591	0,602	-1,8 %
Categorías (12 series)	0,782	0,481	38,4 %
Centro-plato (6 series)	0,367	0,530	-44,4 %




Figura 21: La ganancia del modelo con regresores no es monótona en el nivel de agregación.

La hipótesis se cumple parcialmente. El modelo con regresores mejora de manera contundente en el nivel intermedio: reduce el error un 38 % y es el mejor modelo en 9 de las 12 categorías, pero **empeora** en el nivel centro-plato, que es el más desagregado de todos y donde la hipótesis predecía la mayor ganancia.





Figura 22: Error de proyección por categoría de plato.




11 de 12 categorías mejoran con regresores; 5 de 6 combinaciones centro-plato empeoran.

Figura 23: Serie por serie: dónde gana y dónde pierde el modelo con regresores.

La explicación no está en el nivel de agregación, y se puede verificar en los datos:

Los regresores dejan de moverse justo en la ventana que hay que proyectar

Desvío estándar de cada palanca comercial, por nivel de agregación y tramo de la muestra



En el nivel centro-plato el desvío de las campañas de email en validación es cero. No hubo campañas en las semanas 136-145.

Figura 24: Variación de los regresores por nivel y por tramo de la muestra.

En las semanas 136 a 145 la empresa no lanzó ni una sola campaña de correo sobre ninguna de las seis combinaciones analizadas. El desvío estándar de ese regresor en la ventana de validación es cero, y el de los descuentos cae de 0,094 a 0,029. Es decir, el regresor es prácticamente constante. A nivel de categoría, en cambio, los regresores siguen variando casi igual que en el entrenamiento, porque agregan sobre muchos platos.

El principio que se desprende es más general que este caso particular: **un modelo con variables exógenas no aporta por tener regresores significativos, sino porque esos regresores varían en el período que se quiere proyectar.** Cuando no varían, los parámetros adicionales solo aportan ruido de estimación, afectando la precisión del pronóstico. En el nivel centro-plato el costo es alto porque los coeficientes de descuento son muy grandes, de modo que cualquier movimiento pequeño de precios se amplifica en la proyección.




Figura 25: Efecto de cada acción comercial, combinación por combinación.

A nivel individual los efectos promocionales sí son económicamente grandes, y ahí se ve por qué el agregado los diluye: para la combinación centro 43 / plato 2290 una campaña de correo se asocia a un aumento del 121 % en los pedidos, mientras que para el centro 174 / plato 1885 el efecto no se distingue de cero. La heterogeneidad es enorme, y promediarla hace desaparecer la señal.

3.7. Proyección final para las semanas 146 a 155

Con los criterios anteriores se reestiman los modelos usando las 145 semanas completas y se proyectan las diez semanas siguientes. Los precios y promociones de ese período provienen del archivo de test.




Figura 26: Proyección de la demanda total de la red.

La demanda total proyectada promedia 796.689 pedidos semanales, con un intervalo al 80 % que en la primera semana proyectada va de 611.516 a 804.886 pedidos. La amplitud del intervalo, de alrededor de un tercio del valor central, es una medida de incertidumbre, y es información operativa en la medida que define el margen de seguridad con que conviene aprovisionar/planificar.

Interesa mirar cuánto cambia la proyección según se use o no el plan comercial. Las diferencias semana a semana van de -16,1 % a 13,5 %. Es decir, aunque incorporar el plan comercial no reduzca el error promedio a nivel agregado, **sí cambia significativamente la proyección de semanas puntuales**, que son justamente aquellas en que la empresa planea una acción comercial fuera de lo habitual.

Proyección por categoría de plato, semanas 146 a 155

Modelo ARIMAX estimado sobre las 145 semanas de historia. Banda al 80%




Figura 27: Proyección por categoría de plato.

Tabla 10: Demanda proyectada por categoría para el conjunto de las diez semanas


Categoría	Total 10 semanas	Promedio semanal
Beverages	2.593.478	259.348
Rice Bowl	1.774.370	177.437
Sandwich	1.526.417	152.642
Pizza	371.840	37.184
Other Snacks	326.290	32.629
Extras	296.758	29.676
Starters	203.118	20.312
Desert	152.753	15.275
Seafood	144.193	14.419
Pasta	110.503	11.050
Soup	103.848	10.385
Biryani	39.922	3.992

Éste es el entregable operativo: define cuánta materia prima aprovisionar por familia de producto. Tres categorías (bebidas, bowls de arroz y sándwiches) concentran el 78 % del volumen proyectado, de modo que el esfuerzo de planificación debería concentrarse ahí.

Como control de consistencia, se comparó la proyección agregada contra la suma de las proyecciones por categoría. Acumuladas sobre las diez semanas difieren en un 4,1 %, mientras que las categorías excluidas del modelado representan el 9,9 % del volumen histórico: las dos vías son coherentes entre sí dentro de lo que explica esa exclusión. Las diferencias semana a semana son mayores, y corresponden al ruido de dos modelos estimados de forma independiente.

Proyección de las seis combinaciones centro-plato de mayor volumen

Modelo ARIMA sobre $\log(\text{pedidos})$, semanas 146 a 155. Banda al 80%



Se usa ARIMA y no ARIMAX porque en este nivel los regresores no mejoraron la proyección fuera de muestra.

Figura 28: Proyección de las seis combinaciones centro-plato de mayor volumen.

Para el nivel centro-plato se usa el modelo **sin** variables exógenas, siguiendo la evidencia de la sección anterior.

4. Limitaciones del análisis

Sobre el alcance de las conclusiones causales. Los coeficientes estimados son asociaciones, no efectos causales. Y no son representativas en tanto las promociones y los descuentos no se asignan al azar. Así, es razonable que la empresa promocióne los platos cuya demanda espera alta, lo que sesga los coeficientes al alza. El trabajo es de pronóstico, y para pronosticar esa endogeneidad no es un problema, ya que interesa la capacidad predictiva, no la identificación. Pero invalida interpretar los coeficientes como efectos causales del tipo: “si promocionáramos tanto más, venderíamos tanto más”. Responder eso requiere variación exógena en la asignación de promociones, o un diseño de panel con efectos fijos que es justamente la técnica que aquí se descartó.

Sobre la estacionalidad. Con 2,8 ciclos anuales no se puede descartar que exista estacionalidad y que la muestra sea demasiado corta para detectarla. La conclusión correcta es que no hay evidencia de estacionalidad anual identificable con estos datos, no que no exista. Un año más de historia podría cambiar esa conclusión.

Sobre el calendario. El dataset no trae fechas reales, de modo que no es posible incorporar feriados, eventos deportivos, clima ni estacionalidad de calendario; variables que en la industria gastronómica suelen ser determinantes. Es probablemente la limitación más severa: buena parte de la varianza residual que el modelo no explica podría deberse a eventos de calendario que el dataset no permite observar.

Sobre la cobertura del modelado. Se modelaron explícitamente el agregado, doce categorías y seis combinaciones centro-plato; no las 3.597 series individuales que pedía la competencia original. Extender el enfoque a todas ellas es directo en términos de código pero requiere resolver el tratamiento de las series cortas y discontinuas, y modelos de conteo para series de volumen bajo, donde la aproximación normal en logaritmos deja de ser adecuada, y donde incluso algunos métodos no pueden ser aplicados sin otros supuestos o transformaciones.

Sobre la coherencia entre niveles. Las proyecciones de los distintos niveles se estimaron de forma independiente, de modo que no suman exactamente. La literatura ofrece métodos de reconciliación de pronósticos jerárquicos que imponen esa coherencia y que suelen mejorar la precisión de todos los niveles a la vez. Junto con el punto anterior, constituyen la extensión natural de este trabajo.

Sobre la dimensión intra-producto de la respuesta al precio. El análisis exploratorio mostró que la sensibilidad de la demanda al precio es un fenómeno de cada producto consigo mismo: al controlar por la identidad de la combinación centro-plato, el poder explicativo se multiplica por 7,1. Los modelos de este trabajo capturan esa dimensión sólo de forma indirecta, estimando series por separado en cada nivel de agregación. La herramienta natural para estimarla de manera explícita es un modelo de panel con efectos fijos por combinación centro-plato, que es justamente la técnica descartada en la Parte 1 por no producir proyecciones. En fin, la técnica que mejor identifica el efecto del precio no es la que mejor responde la pregunta de negocio. Un trabajo más ambicioso usaría las dos de forma complementaria.

Sobre la asimetría de la respuesta al precio. El modelo trata el descuento de forma lineal y simétrica, cuando es plausible que la demanda reaccione distinto a una baja de precio que a un recargo. No se estimó una respuesta asimétrica porque los datos no lo permiten: los recargos superiores al 2 % son el 0,8 % de las observaciones, masa insuficiente para identificar una pendiente propia.

5. Conclusiones

El trabajo construyó un sistema de pronóstico de demanda a diez semanas para una red de 77 centros de distribución de comida, usando modelos ARIMA y ARIMAX sobre 145 semanas de historia, y respondió las dos preguntas planteadas en la Parte 1.

Sobre la **pregunta operativa**, el modelo seleccionado proyecta la demanda semanal total con un error porcentual absoluto medio del 9,2 % en validación cruzada, frente al 11,9 % del pronóstico ingenuo: una mejora de alrededor de un cuarto del error. A nivel de categoría de producto, que es el nivel en el que se decide la compra de insumos, el modelo con información comercial alcanza un MASE promedio de 0,48, menos de la mitad del error de un pronóstico ingenuo. En conclusión, el sistema es utilizable para planificar aprovisionamiento de insumos y fuerza de trabajo.

Sobre la **pregunta econométrica** (cuánto aporta conocer el plan comercial) la respuesta es reveladora: **aporta cuando y donde las palancas comerciales efectivamente se mueven en el período proyectado**. En el agregado no aporta, porque la empresa mantiene sus indicadores promocionales dentro de un rango estrecho de dimensiones. En el nivel de categoría aporta mucho, porque ahí las campañas se concentran y la variación sobrevive. En el nivel de combinación individual (centro-plato) no aportó en este período concreto, porque durante las diez semanas proyectadas no hubo campañas que aprovechar.

En conclusión, el análisis permite destacar dos observaciones. Primero, evaluar con una sola ventana de backtesting puede elegir el modelo equivocado (en este caso, habría llevado a concluir que ningún modelo supera al pronóstico ingenuo, lo que la validación cruzada desmiente). Segundo, el mejor ajuste dentro de la muestra no anticipa el mejor desempeño fuera de ella. El modelo con variables exógenas gana por amplio margen en criterio de información, pero no mejora la proyección agregada.

Anexo — Reproducibilidad

El repositorio contiene los datos, los scripts y este informe. El proyecto se ejecuta completo desde la raíz del repositorio con `Rscript R/run_all.R`, que regenera todas las figuras y tablas citadas. Todas las rutas son relativas y la semilla aleatoria está fijada en 2026. Los scripts están numerados en el orden en que deben ejecutarse: preparación de datos, análisis exploratorio, modelado agregado, modelado desagregado y proyección final.